a

Análisis de Sistemas Dinámicos y Estimacióna

EL3204-1

Pauta Auxiliar 11 - Estimación

Prof Marcos Orchard - Sebastian Espinoza.
Prof Auxiliar Erik Sáez Aravena.

Resumen

Este auxiliar cubre conceptos fundamentales de la teoría de estimación de parámetros, que complementa los temas de detección vistos anteriormente. En problemas de detección, el espacio paramétrico Θ era discreto y finito, pero ahora trabajamos con un conjunto **infinito no numerable** de posibles valores para el parámetro que queremos estimar (un continuo).

1. Conceptos Básicos de Estimación

Algunos conceptos importante a considerar son:

1. **Espacio de observación ($\mathbb{X}$):** Espacio donde la variable aleatoria $X \in \mathbb{X}$ toma valores. Para vectores aleatorios, $\mathbb{X}^n$ representa el espacio producto.

2. **Espacio de decisión (Θ):** En estimación, es un conjunto **infinito no numerable** de valores (a diferencia de detección donde era finito). Ejemplos: $\Theta = \mathbb{R}^+$ para estimar amplitudes, $\Theta = \mathbb{R}$ para estimar medias.

3. **Familia de distribuciones paramétricas (J_θ):** Conjunto de distribuciones indexadas por θ:

$$J_\theta = \{P_X(x|\theta) : \theta \in \Theta\}$$

4. **Estimador:** Una función $\hat{\theta}(x_1, \ldots, x_n)$ que depende de las observaciones y entrega una estimación del parámetro θ asociado a la distribución $P_X(x|\theta)$.

2. Propiedades de los Estimadores

1. **Estimador Insesgado:** Un estimador $\hat{\theta}(x_1, \ldots, x_n)$ es insesgado si:

$$\mathbb{E}[\hat{\theta}(X_1, \ldots, X_n)] = \theta$$

   Es decir, en promedio el estimador entrega el valor verdadero del parámetro.

2. **Estimador Asintóticamente Insesgado:** Si el sesgo tiende a cero cuando $n \to \infty$:

$$\lim_{n\to\infty} \mathbb{E}[\hat{\theta}(X_1, \ldots, X_n)] = \theta$$

3. **Estimador Consistente:** Un estimador es consistente si converge en probabilidad al valor verdadero:

$$\lim_{n\to\infty} P_X(|\hat{\theta}(X_1, \ldots, X_n) - \theta| > \epsilon) = 0 \quad \forall \epsilon > 0$$

4. **Observación:** Mediante la desigualdad de Chebyshev, si un estimador es insesgado y su varianza tiende a cero cuando $n \to \infty$, entonces es consistente:

$$\lim_{n\to\infty} \mathrm{Var}(\hat{\theta}(X_1, \ldots, X_n)) = 0 \implies \text{consistencia}$$

3. Condiciones de Regularidad

Las condiciones de regularidad permiten intercambiar el orden de derivación e integración en la función de verosimilitud. Bajo estas condiciones se cumple:

1. **Primera condición:** La esperanza de la derivada de la log-verosimilitud es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right] = 0$$

2. **Segunda condición:** La esperanza de un término específico es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial^2 L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right] = 0$$

3. **Identidad de Bartlett:** Relaciona la varianza con su segunda derivada:

$$\mathbb{E}_{X_1^n}\left[\left(\frac{\partial \ln L}{\partial\theta}\right)^2\right] = -\mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L}{\partial\theta^2}\right]$$

   Esta identidad permite calcular la información de Fisher de dos formas equivalentes.

4. Información de Fisher

La información de Fisher $\mathcal{I}(\theta)$ cuantifica cuánta información sobre el parámetro θ contienen las observaciones:

$$\mathcal{I}(\theta) = \mathbb{E}\left[\left(\frac{\partial \ln f(X|\theta)}{\partial\theta}\right)^2\right] = -\mathbb{E}\left[\frac{\partial^2 \ln f(X|\theta)}{\partial\theta^2}\right]$$

Propiedad Aditiva: Para muestras i.i.d., la información de Fisher es aditiva:

$$\mathcal{I}_n(\theta) = n \cdot \mathcal{I}_1(\theta)$$

Esta propiedad refleja que más observaciones independientes proporcionan más información sobre el parámetro.

5. Cota de Cramér-Rao

La cota de Cramér-Rao establece un límite inferior para la varianza de cualquier estimador insesgado:

$$\mathrm{Var}(\hat{\theta}) \geq \frac{1}{\mathcal{I}(\theta)}$$

1. **Estimador Eficiente:** Un estimador insesgado que alcanza la cota de Cramér-Rao se llama **eficiente** o **de mínima varianza**

2. **Interpretación:** La información de Fisher es inversamente proporcional a la mínima varianza posible. Más información $\implies$ menor varianza mínima.

6. Estimador de Máxima Verosimilitud (ML)

El estimador de máxima verosimilitud se obtiene maximizando la función de verosimilitud:

$$\hat{\theta}_{ML} = \arg\max_{\theta} L(x_1, \ldots, x_n|\theta) = \arg\max_{\theta} \ln L(x_1, \ldots, x_n|\theta)$$

Propiedades del estimador ML:

- Bajo condiciones de regularidad, es asintóticamente insesgado
- Es consistente
- Es asintóticamente eficiente (alcanza la cota de Cramér-Rao cuando $n \to \infty$)
- Es invariante bajo transformaciones: si $\hat{\theta}_{ML}$ es el ML de θ, entonces $g(\hat{\theta}_{ML})$ es el ML de $g(\theta)$

Método de solución: Criterio de la primera derivada:

$$\left.\frac{\partial \ln L(x_1, \ldots, x_n|\theta)}{\partial \theta}\right|_{\theta=\hat{\theta}_{ML}} = 0$$

Verificar que la segunda derivada es negativa para confirmar que es un máximo.

7. Resumen de Verificaciones para un Estimador

Para analizar completamente un estimador $\hat{\theta}$, verificar:

1. **Insesgamiento:** Calcular $\mathbb{E}[\hat{\theta}]$ y verificar si es igual a θ
2. **Consistencia:** Verificar que $\lim_{n\to\infty} \mathrm{Var}(\hat{\theta}) = 0$ (si es insesgado)
3. **Varianza:** Calcular $\mathrm{Var}(\hat{\theta})$ explícitamente
4. **Eficiencia:** Calcular $\mathcal{I}(\theta)$ y comparar $\mathrm{Var}(\hat{\theta})$ con $\frac{1}{\mathcal{I}(\theta)}$

1. Bajo las condiciones de regularidad de la Definición 3.2 del apunte, verifique si el vector aleatorio $X_1, \ldots, X_n$ es i.i.d. con distribución $P_{X_1^n}(\cdot|\theta)$ entoncesa

$$\mathbb{E}_{X_1^n}\left(\left(\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right)^2\right) = -\mathbb{E}_{X_1^n}\left(\frac{\partial^2 \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right). \tag{1}$$

Solución:

Para demostrar esta identidad, utilizaremos las siguientes condiciones de regularidad que permiten intercambiar el orden de derivación e integración:

Primera condición de regularidad: La esperanza de la primera derivada de la log-verosimilitud es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right] = 0 \tag{2}$$

Segunda condición de regularidad: La esperanza de un término específico es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial^2 L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right] = 0 \tag{3}$$

Partimos de la primera condición de regularidad:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right] = 0$$

Y derivamos ambos lados de esta ecuación respecto a θ. Del lado izquierdo, bajo condiciones de regularidad podemos intercambiar la derivada con la esperanza (que es una integral):

$$\frac{\partial}{\partial\theta}\underbrace{\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right]}_{=0} = \mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right]$$

Del lado derecho, derivamos la constante 0:

$$\frac{\partial}{\partial\theta}(0) = 0$$

Por lo tanto:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right] = 0$$

Este resultado nos dice que la esperanza de la segunda derivada de la log-verosimilitud es cero. Ahora necesitamos conectar estos dos resultados. Partimos de la propiedad fundamental del logaritmo aplicada a la función de verosimilitud:

$$\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta} = \frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta}$$

Ahora derivamos ambos lados respecto a θ para obtener la segunda derivada. Aplicamos la regla del producto en el lado derecho, donde tenemos un producto de dos funciones: $\frac{1}{L(X_1,\ldots,X_n|\theta)}$ y $\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta}$. Recordemos la regla del producto: si $h(\theta) = f(\theta)\cdot g(\theta)$, entonces $\frac{dh}{d\theta} = \frac{df}{d\theta}\cdot g + f\cdot\frac{dg}{d\theta}$.

Aplicando esto a lo siguiente:

$$\frac{\partial^2 \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta^2} = \frac{\partial}{\partial\theta}\left[\frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right]$$

Desarrollamos usando la regla del producto:

$$= \underbrace{\frac{\partial}{\partial\theta}\left(\frac{1}{L(X_1,\ldots,X_n|\theta)}\right)}_{\text{derivada del primer factor}}\cdot\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta} + \frac{1}{L(X_1,\ldots,X_n|\theta)}\cdot\underbrace{\frac{\partial^2 L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}}_{\text{derivada del segundo factor}}$$

Para el primer término, calculamos la derivada de $\frac{1}{L(X_1,\ldots,X_n|\theta)}$ usando la regla de la cadena:

$$\frac{\partial}{\partial\theta}\left(\frac{1}{L(X_1,\ldots,X_n|\theta)}\right) = -\frac{1}{L(X_1,\ldots,X_n|\theta)^2}\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta}$$

Sustituyendo esto en la expresión anterior:

$$\frac{\partial^2 \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta^2} = -\frac{1}{L(X_1,\ldots,X_n|\theta)^2}\left(\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right)^2 + \frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial^2 L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}$$

Ahora observamos que el primer término se puede reescribir. Notemos que:

$$\frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta} = \frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}$$

Por lo tanto:

$$\frac{1}{L(X_1,\ldots,X_n|\theta)^2}\left(\frac{\partial L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right)^2 = \left(\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right)^2$$

Finalmente, sustituyendo esto obtenemos:

$$\boxed{\frac{\partial^2 \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta^2} = -\left(\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right)^2 + \frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial^2 L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}}$$

Tomando esperanza en ambos lados y usando que $\mathbb{E}\left[\frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial^2 L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right] = 0$ (otra condición de regularidad):

$$\mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right] = -\mathbb{E}_{X_1^n}\left[\left(\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right)^2\right]$$

2. Compruebe que si el vector aleatorio $X_1, \ldots, X_n$ es i.i.d. con distribución $P_{X_1^n}(\cdot|\theta)$ entonces la información de Fisher es aditiva, es decir:

$$\mathcal{I}_n(\theta) \triangleq \mathbb{E}_{X_1^n}\left(\left(\frac{\partial \ln L(X_1, X_2, \ldots, X_n|\theta)}{\partial\theta}\right)^2\right) = n \cdot \mathcal{I}_1(\theta). \tag{4}$$

Solución:

Dado que $X_1, \ldots, X_n$ son variables i.i.d., la función de verosimilitud se puede expresar como el producto de las densidades individuales:

$$L(X_1, \ldots, X_n|\theta) = \prod_{i=1}^{n} f(X_i|\theta)$$

Tomando logaritmo en ambos lados:

$$\ln L(X_1, \ldots, X_n|\theta) = \sum_{i=1}^{n} \ln f(X_i|\theta)$$

Derivando respecto a θ y usando la linealidad de la derivada:

$$\frac{\partial}{\partial\theta} \ln L(X_1, \ldots, X_n|\theta) = \sum_{i=1}^{n} \frac{\partial \ln f(X_i|\theta)}{\partial\theta}$$

Ahora calculamos la esperanza del cuadrado de esta derivada. Notemos que:

$$\mathbb{E}_{X_1^n}\left[\left(\frac{\partial \ln L}{\partial\theta}\right)^2\right] = \mathbb{E}_{X_1^n}\left[\left(\sum_{i=1}^{n} \frac{\partial \ln f(X_i|\theta)}{\partial\theta}\right)^2\right]$$

Expandiendo el cuadrado:

$$= \mathbb{E}_{X_1^n}\left[\sum_{i=1}^{n}\left(\frac{\partial \ln f(X_i|\theta)}{\partial\theta}\right)^2 + 2\sum_{i<j} \frac{\partial \ln f(X_i|\theta)}{\partial\theta} \cdot \frac{\partial \ln f(X_j|\theta)}{\partial\theta}\right]$$

Por linealidad de la esperanza:

$$= \sum_{i=1}^{n} \mathbb{E}_{X_i}\left[\left(\frac{\partial \ln f(X_i|\theta)}{\partial\theta}\right)^2\right] + 2\sum_{i<j} \mathbb{E}_{X_i, X_j}\left[\frac{\partial \ln f(X_i|\theta)}{\partial\theta} \cdot \frac{\partial \ln f(X_j|\theta)}{\partial\theta}\right]$$

Como las variables son independientes, la esperanza del producto es el producto de las esperanzas. Por las condiciones de regularidad, $\mathbb{E}_{X_i}\left[\frac{\partial \ln f(X_i|\theta)}{\partial\theta}\right] = 0$, por lo que todos los términos cruzados se anulan:

$$2\sum_{i<j} \mathbb{E}_{X_i}\left[\frac{\partial \ln f(X_i|\theta)}{\partial\theta}\right] \cdot \mathbb{E}_{X_j}\left[\frac{\partial \ln f(X_j|\theta)}{\partial\theta}\right] = 0$$

Por lo tanto:

$$\mathcal{I}_n(\theta) = \sum_{i=1}^{n} \mathbb{E}_{X_i}\left[\left(\frac{\partial \ln f(X_i|\theta)}{\partial \theta}\right)^2\right]$$

Como todas las variables son idénticamente distribuidas, cada término es igual a $\mathcal{I}_1(\theta)$:

$$\mathcal{I}_n(\theta) = n \cdot \mathcal{I}_1(\theta)$$

3. [**Propuesto**]Muestre que para cualquier estimador τ_n de θ su error de estimación se puede descomponer como varianza más sesgo, es decir:

$$\mathbb{E}_{X_1^n}\left((\tau_n(X_1^n) - \theta)^2\right) = \mathrm{Var}(\tau_n(X_1^n)) + \left(\mathbb{E}_{X_1^n}(\tau_n(X_1^n)) - \theta\right)^2. \tag{5}$$

Solución:

Para demostrar esta descomposición, partimos del error cuadrático medio (MSE) y realizamos manipulaciones algebraicas. Sea $\hat{\theta} = \tau_n(X_1^n)$ el estimador y denotemos $\mathbb{E}[\hat{\theta}]$ como su esperanza.Comenzamos con el MSE:

$$\mathrm{MSE}(\hat{\theta}) = \mathbb{E}_{X_1^n}\left[(\hat{\theta} - \theta)^2\right]$$

Sumamos y restamos la esperanza del estimador $\mathbb{E}[\hat{\theta}]$ dentro del cuadrado:

$$\mathrm{MSE}(\hat{\theta}) = \mathbb{E}_{X_1^n}\left[\left((\hat{\theta} - \mathbb{E}[\hat{\theta}]) + (\mathbb{E}[\hat{\theta}] - \theta)\right)^2\right]$$

Expandiendo el cuadrado del binomio:

$$\mathrm{MSE}(\hat{\theta}) = \mathbb{E}_{X_1^n}\left[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2 + 2(\hat{\theta} - \mathbb{E}[\hat{\theta}])(\mathbb{E}[\hat{\theta}] - \theta) + (\mathbb{E}[\hat{\theta}] - \theta)^2\right]$$

Por la linealidad de la esperanza, podemos separar en tres términos:

$$\mathrm{MSE}(\hat{\theta}) = \mathbb{E}_{X_1^n}\left[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2\right] + \mathbb{E}_{X_1^n}\left[2(\hat{\theta} - \mathbb{E}[\hat{\theta}])(\mathbb{E}[\hat{\theta}] - \theta)\right] + \mathbb{E}_{X_1^n}\left[(\mathbb{E}[\hat{\theta}] - \theta)^2\right]$$

Analicemos cada término:

- **Primer término:** Este es la definición de la varianza del estimador:

$$\mathbb{E}_{X_1^n}\left[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2\right] = \mathrm{Var}(\hat{\theta})$$

- **Tercer término:** Como $\mathbb{E}[\hat{\theta}]$ y θ son constantes (no dependen de X_1^n), la esperanza no afecta este término:

$$\mathbb{E}_{X_1^n}\left[(\mathbb{E}[\hat{\theta}] - \theta)^2\right] = (\mathbb{E}[\hat{\theta}] - \theta)^2$$

  Este término representa el cuadrado de la diferencia entre el valor esperado del estimador y el valor verdadero del parámetro.

- **Segundo término:** Factorizamos las constantes fuera de la esperanza:

$$\mathbb{E}_{X_1^n}\left[2(\hat{\theta}-\mathbb{E}[\hat{\theta}])(\mathbb{E}[\hat{\theta}]-\theta)\right] = 2(\mathbb{E}[\hat{\theta}]-\theta)\cdot\mathbb{E}_{X_1^n}\left[\hat{\theta}-\mathbb{E}[\hat{\theta}]\right]$$

Pero sabemos que:

$$\mathbb{E}_{X_1^n}\left[\hat{\theta}-\mathbb{E}[\hat{\theta}]\right] = \mathbb{E}_{X_1^n}[\hat{\theta}]-\mathbb{E}[\hat{\theta}] = \mathbb{E}[\hat{\theta}]-\mathbb{E}[\hat{\theta}] = 0$$

Por lo tanto, el segundo término es cero:

$$2(\mathbb{E}[\hat{\theta}]-\theta)\cdot 0 = 0$$

Combinando todos los términos, obtenemos la descomposición deseada:

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{Var}(\hat{\theta}) + (\mathbb{E}[\hat{\theta}]-\theta)^2$$

O equivalentemente:

$$\mathbb{E}_{X_1^n}\left[(\tau_n(X_1^n)-\theta)^2\right] = \mathrm{Var}(\tau_n(X_1^n)) + \left(\mathbb{E}_{X_1^n}(\tau_n(X_1^n))-\theta\right)^2$$

Esta descomposición es fundamental en teoría de estimación, pues muestra que el error cuadrático medio se puede descomponer en dos componentes: la varianza del estimador (que mide su dispersión) y el cuadrado de la diferencia entre su valor esperado y el valor verdadero del parámetro (que mide qué tan lejos está en promedio del valor real).

4. Suponga una variable aleatoria $X \sim \mathcal{N}(\mu, \sigma^2)$ y muestras de dicha variable a $X_1, X_2, \ldots, X_n$ i.i.d. Popularmente, se suelen estimar los dos parámetros de esta distribución como:

$$\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} \tag{6}$$

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^n (x_i-\mu)^2 \tag{7}$$

(a) ¿Son los estimadores de ambos parámetros insesgados?

Solución:

1. **Para $\hat{\mu}$:**

Calculamos la esperanza del estimador:

$$\mathbb{E}[\hat{\mu}] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^n X_i\right] = \frac{1}{n}\sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n}\sum_{i=1}^n \mu = \frac{n\mu}{n} = \mu$$

Por lo tanto, $\hat{\mu}$ es un **estimador insesgado** de μ.

2. **Para $\hat{\sigma}^2$:**

   Calculamos la esperanza del estimador:

$$\mathbb{E}[\hat{\sigma}^2] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[(X_i-\mu)^2]$$

   Sabemos que $\mathbb{E}[(X_i-\mu)^2] = \mathrm{Var}(X_i) = \sigma^2$, entonces:

$$\mathbb{E}[\hat{\sigma}^2] = \frac{1}{n}\sum_{i=1}^{n}\sigma^2 = \frac{n\sigma^2}{n} = \sigma^2$$

   Por lo tanto, $\hat{\sigma}^2$ también es un **estimador insesgado** de σ^2.

Por lo tanto ambos estimadores son insesgados.

(b) Determine si los estimadores son consistentes. *Indicación:* Utilice el hecho que si $Z \sim \mathcal{N}(0,1)$ entonces $Y = Z^2 \sim \chi^2_{(1)}$ con $\mathrm{Var}(Y) = 2 \cdot 1$.

Solución:
Un estimador $\hat{\theta}_n$ es consistente si $\lim_{n\to\infty}\mathbb{P}(|\hat{\theta}_n - \theta| > \epsilon) = 0$ para todo $\epsilon > 0$. Por la desigualdad de Chebyshev, si el sesgo tiende a cero y la varianza tiende a cero cuando $n \to \infty$, entonces el estimador es consistente.

- **Para $\hat{\mu}$:**

  Ya vimos que el sesgo es cero. Ahora calculamos la varianza:

$$\mathrm{Var}(\hat{\mu}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n}X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}\cdot n\sigma^2 = \frac{\sigma^2}{n}$$

  Como $\lim_{n\to\infty}\frac{\sigma^2}{n} = 0$, el estimador $\hat{\mu}$ es **consistente**.

- **Para $\hat{\sigma}^2$:**

  El sesgo es cero. Ahora calculamos la varianza. Definimos $Z_i = \frac{X_i-\mu}{\sigma} \sim \mathcal{N}(0,1)$, entonces:

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2 = \frac{\sigma^2}{n}\sum_{i=1}^{n}Z_i^2$$

  Como $Z_i^2 \sim \chi^2_{(1)}$, tenemos $\mathrm{Var}(Z_i^2) = 2$. Las variables son independientes, entonces:

$$\mathrm{Var}(\hat{\sigma}^2) = \mathrm{Var}\left(\frac{\sigma^2}{n}\sum_{i=1}^{n}Z_i^2\right) = \frac{\sigma^4}{n^2}\sum_{i=1}^{n}\mathrm{Var}(Z_i^2) = \frac{\sigma^4}{n^2}\cdot 2n = \frac{2\sigma^4}{n}$$

  Como $\lim_{n\to\infty}\frac{2\sigma^4}{n} = 0$, el estimador $\hat{\sigma}^2$ es **consistente**.

Ambos estimadores son consistentes.

(c) Obtenga la cota de Cramer-Rao de cada parámetro ¿Se esta cumpliendo el criterio de mínima varianza?

Solución:
Para obtener la cota de Cramér-Rao, necesitamos calcular la información de Fisher. La densidad de probabilidad de una variable $X \sim \mathcal{N}(\mu, \sigma^2)$ es:

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

La log-verosimilitud para n observaciones i.i.d. es:

$$\ln L(\mu, \sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - \mu)^2$$

- **Para μ:**

  Calculamos la primera derivada:

  $$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i - \mu)$$

  La segunda derivada:

  $$\frac{\partial^2 \ln L}{\partial \mu^2} = -\frac{n}{\sigma^2}$$

  La información de Fisher es:

  $$\mathcal{I}_n(\mu) = -\mathbb{E}\left[\frac{\partial^2 \ln L}{\partial \mu^2}\right] = \frac{n}{\sigma^2}$$

  La cota de Cramér-Rao para μ es:

  $$\mathrm{Var}(\hat{\mu}) \geq \frac{1}{\mathcal{I}_n(\mu)} = \frac{\sigma^2}{n}$$

  Como $\mathrm{Var}(\hat{\mu}) = \frac{\sigma^2}{n}$, el estimador $\hat{\mu}$ **alcanza la cota de Cramér-Rao** y es de **mínima varianza**.

- **Para σ^2:**

  Calculamos la primera derivada:

  $$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^{n}(x_i - \mu)^2$$

  La segunda derivada:

  $$\frac{\partial^2 \ln L}{\partial (\sigma^2)^2} = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6}\sum_{i=1}^{n}(x_i - \mu)^2$$

Tomando esperanza:

$$\mathbb{E}\left[\frac{\partial^2 \ln L}{\partial(\sigma^2)^2}\right] = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6}\cdot n\sigma^2 = \frac{n}{2\sigma^4} - \frac{n}{\sigma^4} = -\frac{n}{2\sigma^4}$$

La información de Fisher es:

$$\mathcal{I}_n(\sigma^2) = -\mathbb{E}\left[\frac{\partial^2 \ln L}{\partial(\sigma^2)^2}\right] = \frac{n}{2\sigma^4}$$

La cota de Cramér-Rao para σ^2 es:

$$\mathrm{Var}(\hat{\sigma}^2) \geq \frac{1}{\mathcal{I}_n(\sigma^2)} = \frac{2\sigma^4}{n}$$

Como $\mathrm{Var}(\hat{\sigma}^2) = \frac{2\sigma^4}{n}$, el estimador $\hat{\sigma}^2$ también **alcanza la cota de Cramér-Rao** y es de **mínima varianza**.

Ambos estimadores cumplen el criterio de mínima varianza.

5. Considere un sistema de modulación AM que genera una señal discreta

$$s(k) = A\cdot\cos\left(\frac{2\pi}{T}\cdot k\right) \tag{8}$$

donde $k \in \{1,\ldots,n\}$, que depende del parámetro A y donde $T > 0$ es un número entero conocido. $(s(k))_{k=1,\ldots,n}$ no es observable directamente si no por medio de un ruido aditivo:

$$X_k(w) = s(k) + N_k(w) \tag{9}$$

Donde $N_1(w), N_2(w), \ldots, N_n(w)$ son variables aleatorias gaussianas independientes e idénticamente distribuidas con media cero y varianza $\sigma^2 > 0$.

(a) Notar que $X_1,\ldots,X_n$ son variables aleatorias gaussianas e independientes. Con ello determine su distribución conjunta $f_X(x_1,\ldots,x_k|A)$.

Solución:
Dado que $X_k = s(k) + N_k$ donde $N_k \sim \mathcal{N}(0,\sigma^2)$, entonces:

$$X_k \sim \mathcal{N}\left(s(k),\sigma^2\right) = \mathcal{N}\left(A\cos\left(\frac{2\pi k}{T}\right),\sigma^2\right)$$

La densidad de probabilidad de cada X_k es:

$$f_{X_k}(x_k|A) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)^2}{2\sigma^2}\right)$$

Como las variables son independientes, la distribución conjunta es el producto de las densidades marginales:

$$f_X(x_1,\ldots,x_n|A) = \prod_{k=1}^{n} f_{X_k}(x_k|A) = \prod_{k=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)^2}{2\sigma^2}\right)$$

Simplificando:

$$f_X(x_1,\ldots,x_n|A) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\sum_{k=1}^{n}\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)^2\right)$$

(b) Del punto anterior, determine la función de densidad condicional $f_X(x_1,\ldots,x_n|A)$ (también conocida como verosimilitud) y con ello el estimador de máxima verosimilitud de A dadas las observaciones $x_1,\ldots,x_n$, es decir, la solución de:

$$\hat{A}_{ML}(x_1,\ldots,x_n) = \arg\max_{A} \ln(f_X(x_1,\ldots,x_n|A)) \tag{10}$$

Donde $A \in \mathbb{R}^+$.

Indicación: Use el criterio de la primera derivada.

Hint: se debe llegar a una expresión cerrada función de $x_1,\ldots,x_n$ y parámetros conocidos del problema.

Solución:

Tomamos el logaritmo de la función de verosimilitud:

$$\ln f_X(x_1,\ldots,x_n|A) = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{k=1}^{n}\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)^2$$

Para maximizar, derivamos respecto a A e igualamos a cero:

$$\frac{\partial}{\partial A}\ln f_X = -\frac{1}{2\sigma^2}\sum_{k=1}^{n} 2\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)\left(-\cos\left(\frac{2\pi k}{T}\right)\right) = 0$$

Simplificando:

$$\frac{1}{\sigma^2}\sum_{k=1}^{n}\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)\cos\left(\frac{2\pi k}{T}\right) = 0$$

Expandiendo:

$$\sum_{k=1}^{n} x_k\cos\left(\frac{2\pi k}{T}\right) - A\sum_{k=1}^{n}\cos^2\left(\frac{2\pi k}{T}\right) = 0$$

Despejando A:

$$\hat{A}_{ML} = \frac{\sum_{k=1}^{n} x_k \cos\left(\frac{2\pi k}{T}\right)}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)}$$

Para verificar que es un máximo, calculamos la segunda derivada:

$$\frac{\partial^2}{\partial A^2} \ln f_X = -\frac{1}{\sigma^2} \sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right) < 0$$

Como la segunda derivada es negativa, confirmamos que es un máximo.
Por lo tanto, el estimador de máxima verosimilitud es:

$$\boxed{\hat{A}_{ML}(x_1, \ldots, x_n) = \frac{\sum_{k=1}^{n} x_k \cos\left(\frac{2\pi k}{T}\right)}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)}}$$

(c) Verifique que $\hat{A}_{ML}(x_1, \ldots, x_n)$ es insesgado, determine su varianza y con ello muestre que es consistente.

Solución:
Para ver si es insesgado, calculamos la esperanza del estimador.

$$\mathbb{E}[\hat{A}_{ML}] = \mathbb{E}\left[\frac{\sum_{k=1}^{n} X_k \cos\left(\frac{2\pi k}{T}\right)}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)}\right] = \frac{\sum_{k=1}^{n} \mathbb{E}[X_k] \cos\left(\frac{2\pi k}{T}\right)}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)}$$

Como $\mathbb{E}[X_k] = A\cos\left(\frac{2\pi k}{T}\right)$:

$$\mathbb{E}[\hat{A}_{ML}] = \frac{\sum_{k=1}^{n} A\cos\left(\frac{2\pi k}{T}\right)\cos\left(\frac{2\pi k}{T}\right)}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)} = \frac{A\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)} = A$$

Por lo tanto, $\hat{A}_{ML}$ es **insesgado**.
Realizamos el calculo de su Varianza. Denotemos $c_k = \cos\left(\frac{2\pi k}{T}\right)$ y $C = \sum_{k=1}^{n} c_k^2$. Entonces:

$$\hat{A}_{ML} = \frac{1}{C} \sum_{k=1}^{n} X_k c_k$$

La varianza es:

$$\mathrm{Var}(\hat{A}_{ML}) = \mathrm{Var}\left(\frac{1}{C}\sum_{k=1}^{n} X_k c_k\right) = \frac{1}{C^2}\sum_{k=1}^{n} c_k^2 \,\mathrm{Var}(X_k) = \frac{1}{C^2}\sum_{k=1}^{n} c_k^2 \sigma^2 = \frac{\sigma^2 C}{C^2} = \frac{\sigma^2}{C}$$

Por lo tanto:

$$\boxed{\mathrm{Var}(\hat{A}_{ML}) = \frac{\sigma^2}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)}}$$

Para mostrar consistencia, observamos que:

$$\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right) \approx \frac{n}{2} \quad \text{cuando } n \to \infty$$

Por lo tanto:

$$\lim_{n\to\infty} \mathrm{Var}(\hat{A}_{ML}) = \lim_{n\to\infty} \frac{\sigma^2}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)} = \lim_{n\to\infty} \frac{2\sigma^2}{n} = 0$$

Como el sesgo es cero y la varianza tiende a cero cuando $n \to \infty$, el estimador $\hat{A}_{ML}$ es **consistente**.

(d) Demuestre que $\hat{A}_{ML}(x_1, \ldots, x_n)$ es estimador insesgado de A de mínima varianza.
Hint: Utilizar la cota de Cramer-Rao y concluya su análisis.

Solución:
Para demostrar que es de mínima varianza, calcularemos la información de Fisher y verificaremos si el estimador alcanza la cota de Cramér-Rao.
La log-verosimilitud es:

$$\ln L(A) = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{k=1}^{n}\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)^2$$

La primera derivada:

$$\frac{\partial \ln L}{\partial A} = \frac{1}{\sigma^2}\sum_{k=1}^{n}\left(x_k - A\cos\left(\frac{2\pi k}{T}\right)\right)\cos\left(\frac{2\pi k}{T}\right)$$

La segunda derivada:

$$\frac{\partial^2 \ln L}{\partial A^2} = -\frac{1}{\sigma^2}\sum_{k=1}^{n}\cos^2\left(\frac{2\pi k}{T}\right)$$

La información de Fisher es:

$$\mathcal{I}_n(A) = -\mathbb{E}\left[\frac{\partial^2 \ln L}{\partial A^2}\right] = \frac{1}{\sigma^2}\sum_{k=1}^{n}\cos^2\left(\frac{2\pi k}{T}\right)$$

La cota de Cramér-Rao para A es:

$$\mathrm{Var}(\hat{A}) \geq \frac{1}{\mathcal{I}_n(A)} = \frac{\sigma^2}{\sum_{k=1}^{n}\cos^2\left(\frac{2\pi k}{T}\right)}$$

Como calculamos en la parte anterior:

$$\mathrm{Var}(\hat{A}_{ML}) = \frac{\sigma^2}{\sum_{k=1}^{n} \cos^2\left(\frac{2\pi k}{T}\right)}$$

Por lo tanto:

$$\mathrm{Var}(\hat{A}_{ML}) = \frac{1}{\mathcal{I}_n(A)}$$

Esto demuestra que $\hat{A}_{ML}$ **alcanza la cota de Cramér-Rao**. El estimador de máxima verosimilitud $\hat{A}_{ML}$ para el sistema de modulación AM es óptimo en el sentido de que minimiza la varianza entre todos los estimadores insesgados de A.