Ingeniería Eléctrica
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS UNIVERSIDAD DE CHILE

Análisis de Sistemas Dinámicos y Estimación

EL3204-1

Pauta Auxiliar 13 - Repaso Examen

Prof Marcos Orchard - Sebastian Espinoza.
Prof Auxiliar Erik Sáez Aravena.

Resumen

Este auxiliar cubre conceptos fundamentales de la teoría de estimación de parámetros, que complementa los temas de detección vistos anteriormente. En problemas de detección, el espacio paramétrico Θ era discreto y finito, pero ahora trabajamos con un conjunto **infinito no numerable** de posibles valores para el parámetro que queremos estimar (un continuo).

1. Conceptos Básicos de Estimación

Algunos conceptos importante a considerar son:

1. **Espacio de observación ($\mathbb{X}$):** Espacio donde la variable aleatoria $X \in \mathbb{X}$ toma valores. Para vectores aleatorios, $\mathbb{X}^n$ representa el espacio producto.

2. **Espacio de decisión (Θ):** En estimación, es un conjunto **infinito no numerable** de valores (a diferencia de detección donde era finito). Ejemplos: $\Theta = \mathbb{R}^+$ para estimar amplitudes, $\Theta = \mathbb{R}$ para estimar medias.

3. **Familia de distribuciones paramétricas (J_θ):** Conjunto de distribuciones indexadas por θ:

$$J_\theta = \{P_X(x|\theta) : \theta \in \Theta\}$$

4. **Estimador:** Una función $\hat{\theta}(x_1, \ldots, x_n)$ que depende de las observaciones y entrega una estimación del parámetro θ asociado a la distribución $P_X(x|\theta)$.

2. Propiedades de los Estimadores

1. **Estimador Insesgado:** Un estimador $\hat{\theta}(x_1, \ldots, x_n)$ es insesgado si:

$$\mathbb{E}[\hat{\theta}(X_1, \ldots, X_n)] = \theta$$

   Es decir, en promedio el estimador entrega el valor verdadero del parámetro.

2. **Estimador Asintóticamente Insesgado:** Si el sesgo tiende a cero cuando $n \to \infty$:

$$\lim_{n\to\infty} \mathbb{E}[\hat{\theta}(X_1, \ldots, X_n)] = \theta$$

3. **Estimador Consistente:** Un estimador es consistente si converge en probabilidad al valor verdadero:

$$\lim_{n\to\infty} P_X(|\hat{\theta}(X_1, \ldots, X_n) - \theta| > \epsilon) = 0 \quad \forall \epsilon > 0$$

4. **Observación:** Mediante la desigualdad de Chebyshev, si un estimador es insesgado y su varianza tiende a cero cuando $n \to \infty$, entonces es consistente:

$$\lim_{n\to\infty} \mathrm{Var}(\hat{\theta}(X_1, \ldots, X_n)) = 0 \implies \text{consistencia}$$

3. Condiciones de Regularidad

Las condiciones de regularidad permiten intercambiar el orden de derivación e integración en la función de verosimilitud. Bajo estas condiciones se cumple:

1. **Primera condición:** La esperanza de la derivada de la log-verosimilitud es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\theta)}{\partial\theta}\right] = 0$$

2. **Segunda condición:** La esperanza de un término específico es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{1}{L(X_1,\ldots,X_n|\theta)}\frac{\partial^2 L(X_1,\ldots,X_n|\theta)}{\partial\theta^2}\right] = 0$$

3. **Identidad de Bartlett:** Relaciona la varianza con su segunda derivada:

$$\mathbb{E}_{X_1^n}\left[\left(\frac{\partial \ln L}{\partial\theta}\right)^2\right] = -\mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L}{\partial\theta^2}\right]$$

   Esta identidad permite calcular la información de Fisher de dos formas equivalentes.

4. Información de Fisher

La información de Fisher $\mathcal{I}(\theta)$ cuantifica cuánta información sobre el parámetro θ contienen las observaciones:

$$\mathcal{I}(\theta) = \mathbb{E}\left[\left(\frac{\partial \ln f(X|\theta)}{\partial\theta}\right)^2\right] = -\mathbb{E}\left[\frac{\partial^2 \ln f(X|\theta)}{\partial\theta^2}\right]$$

Propiedad Aditiva: Para muestras i.i.d., la información de Fisher es aditiva:

$$\mathcal{I}_n(\theta) = n \cdot \mathcal{I}_1(\theta)$$

Esta propiedad refleja que más observaciones independientes proporcionan más información sobre el parámetro.

5. Cota de Cramér-Rao

La cota de Cramér-Rao establece un límite inferior para la varianza de cualquier estimador insesgado:

$$\mathrm{Var}(\hat{\theta}) \geq \frac{1}{\mathcal{I}(\theta)}$$

1. **Estimador Eficiente:** Un estimador insesgado que alcanza la cota de Cramér-Rao se llama **eficiente** o **de mínima varianza**

2. **Interpretación:** La información de Fisher es inversamente proporcional a la mínima varianza posible. Más información $\implies$ menor varianza mínima.

6. Estimador de Máxima Verosimilitud (ML)

El estimador de máxima verosimilitud se obtiene maximizando la función de verosimilitud:

$$\hat{\theta}_{ML} = \arg\max_{\theta} L(x_1, \ldots, x_n|\theta) = \arg\max_{\theta} \ln L(x_1, \ldots, x_n|\theta)$$

Método de solución: Criterio de la primera derivada:

$$\left.\frac{\partial \ln L(x_1, \ldots, x_n|\theta)}{\partial \theta}\right|_{\theta=\hat{\theta}_{ML}} = 0$$

Verificar que la segunda derivada es negativa para confirmar que es un máximo.

7. Estimación Bayesiana

En el enfoque bayesiano, el parámetro θ es considerado como una variable aleatoria con una distribución a priori $P_\Theta(\theta)$ o $f_\Theta(\theta)$. Se busca encontrar estimadores basados en la distribución a posteriori:

$$f_{\Theta|X}(\theta|x) = \frac{f_{X|\Theta}(x|\theta) f_\Theta(\theta)}{f_X(x)}$$

- **Estimador MMSE (Minimum Mean Square Error):**

  El estimador que minimiza el error cuadrático medio es la esperanza condicional:

  $$\hat{\theta}_{MMSE}(x) = \mathbb{E}[\Theta|X = x] = \int_{-\infty}^{\infty} \theta \cdot f_{\Theta|X}(\theta|x) d\theta$$

  Para el caso discreto:

  $$\hat{\theta}_{MMSE}(x) = \sum_{\theta} \theta \cdot P_{\Theta|X}(\theta|x)$$

- **Estimador MAP (Maximum A Posteriori):**

  El estimador MAP maximiza la distribución a posteriori:

  $$\hat{\theta}_{MAP}(x) = \arg\max_{\theta} f_{\Theta|X}(\theta|x) = \arg\max_{\theta} f_{X|\Theta}(x|\theta) f_\Theta(\theta)$$

  Para el caso discreto:

  $$\hat{\theta}_{MAP}(x) = \arg\max_{\theta} P_{\Theta|X}(\theta|x) = \arg\max_{\theta} P_{X|\Theta}(x|\theta) P_\Theta(\theta)$$

  En la práctica se trabaja con el logaritmo:

  $$\hat{\theta}_{MAP}(x) = \arg\max_{\theta} \ln f_{X|\Theta}(x|\theta) + \ln f_\Theta(\theta)$$

1. El caso de distribuciones exponenciales es emblemático tanto por su simplicidad analítica, así como por su uso como modelamiento del tiempo de falla en sistemas complejos. Consideremos $\overline{\mathbb{X}} = \mathbb{R}^n$, $\Theta = \mathbb{R}^+$ y una secuencia $X_1^n = X_1, ..., X_n$ de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) tales que $X_i \sim Exponencial\left(\frac{1}{\lambda}\right)$, $i \in \{1, ..., n\}$ con $\lambda > 0$ un parámetro.

   Indicación: Si $X \sim Exponencial(a)$ entonces su función de densidad de probabilidad es

$$f_X(x) = \begin{cases} ae^{-ax} & \text{para } x > 0 \\ 0 & \text{para } x \leq 0 \end{cases}$$

   Donde además $\mathbb{E}(X) = \frac{1}{a}$ y $Var(X) = \frac{1}{a^2}$.

   (a) [1 puntos] Obtenga el estimador de máxima verosimilitud $\hat{\lambda}_{ML}(\cdot)$ del parámetro λ.

Solución:

Resolución (a): Estimador de Máxima Verosimilitud

Para encontrar el estimador de máxima verosimilitud, primero escribimos la función de verosimilitud. Dado que $X_1, \ldots, X_n$ son i.i.d. con $X_i \sim \text{Exponencial}(1/\lambda)$:

$$L(x_1, \ldots, x_n|\lambda) = \prod_{i=1}^{n} f_{X_i}(x_i|\lambda) = \prod_{i=1}^{n} \frac{1}{\lambda} e^{-x_i/\lambda} = \frac{1}{\lambda^n} e^{-\sum_{i=1}^{n} x_i/\lambda} \tag{1}$$

Tomando el logaritmo natural:

$$\ln L(x_1, \ldots, x_n|\lambda) = -n \ln \lambda - \frac{1}{\lambda} \sum_{i=1}^{n} x_i \tag{2}$$

Para encontrar el máximo, derivamos con respecto a λ e igualamos a cero (condición de primer orden):

$$\frac{\partial \ln L}{\partial \lambda} = -\frac{n}{\lambda} + \frac{1}{\lambda^2} \sum_{i=1}^{n} x_i = 0 \tag{3}$$

¿Por qué igualamos la derivada a cero? Porque en cálculo diferencial, los puntos críticos de una función (máximos, mínimos o puntos de inflexión) ocurren donde la derivada es cero o no existe. Cuando la derivada es cero, la pendiente de la función es horizontal en ese punto.
Resolviendo para λ:

$$\frac{1}{\lambda^2} \sum_{i=1}^{n} x_i = \frac{n}{\lambda} \tag{4}$$

$$\sum_{i=1}^{n} x_i = n\lambda \tag{5}$$

$$\lambda = \frac{1}{n} \sum_{i=1}^{n} x_i = \bar{x} \tag{6}$$

¿Por qué este valor es el máximo? Encontramos que $\lambda = \bar{x}$ es un **punto crítico**. Ahora debemos verificar que efectivamente es un **máximo** (y no un mínimo o punto de inflexión). Para esto, usamos el **criterio de la segunda derivada**:
Calculamos la segunda derivada de $\ln L$ con respecto a λ:

$$\frac{\partial^2 \ln L}{\partial \lambda^2} = \frac{\partial}{\partial \lambda}\left(-\frac{n}{\lambda} + \frac{1}{\lambda^2}\sum_{i=1}^{n} x_i\right) = \frac{n}{\lambda^2} - \frac{2}{\lambda^3}\sum_{i=1}^{n} x_i \tag{7}$$

Evaluando en el punto crítico $\lambda = \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$:

$$\left.\frac{\partial^2 \ln L}{\partial \lambda^2}\right|_{\lambda=\bar{x}} = \frac{n}{\bar{x}^2} - \frac{2}{\bar{x}^3}\sum_{i=1}^{n} x_i = \frac{n}{\bar{x}^2} - \frac{2}{\bar{x}^3}(n\bar{x}) = \frac{n}{\bar{x}^2} - \frac{2n}{\bar{x}^2} = -\frac{n}{\bar{x}^2} < 0 \tag{8}$$

Interpretación del criterio de la segunda derivada:

- Si $\frac{\partial^2 \ln L}{\partial \lambda^2} < 0$ (negativa): La función es **cóncava** en ese punto $\Rightarrow$ **MÁXIMO**
- Si $\frac{\partial^2 \ln L}{\partial \lambda^2} > 0$ (positiva): La función es **convexa** en ese punto $\Rightarrow$ MÍNIMO

Como la segunda derivada es **negativa** para todo $\lambda > 0$, confirmamos que $\lambda = \bar{x}$ es efectivamente un **máximo**. Además, como la función es cóncava en todo su dominio (segunda derivada siempre negativa), este máximo es **único y global**.
Por lo tanto, el estimador de máxima verosimilitud es:

$$\boxed{\hat{\lambda}_{ML}(x_1, \ldots, x_n) = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}} \tag{9}$$

(b) [1 puntos] Calcule sesgo y varianza del estimador obtenido en la parte **(a)**.

Solución:

Resolución (b): Sesgo y Varianza del Estimador ML

Calculamos $\mathbb{E}[\hat{\lambda}_{ML}]$:

$$\mathbb{E}[\hat{\lambda}_{ML}] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i] \tag{10}$$

$$= \frac{1}{n}\sum_{i=1}^{n}\lambda = \frac{n\lambda}{n} = \lambda \tag{11}$$

Por lo tanto, $\hat{\lambda}_{ML}$ es un **estimador insesgado**.

Varianza: Como las X_i son independientes:

$$\mathrm{Var}(\hat{\lambda}_{ML}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) \tag{12}$$

$$= \frac{1}{n^2}\sum_{i=1}^{n}\lambda^2 = \frac{n\lambda^2}{n^2} = \frac{\lambda^2}{n} \tag{13}$$

$$\boxed{\mathrm{Var}(\hat{\lambda}_{ML}) = \frac{\lambda^2}{n}} \tag{14}$$

(c) [1 puntos] Demuestre, bajo condiciones de regularidad, que la Información de Fisher admite la siguiente igualdad:

$$\mathcal{I}_n(\lambda) = \mathbb{E}_{X_1,\ldots,X_n}\left\{\left(\frac{\partial \ln L(X_1, X_2, ..., X_n|\lambda)}{\partial\lambda}\right)^2\right\} = -\mathbb{E}_{X_1,\ldots,X_n}\left\{\frac{\partial^2 \ln L(X_1, X_2, ..., X_n|\lambda)}{\partial\lambda^2}\right\}.$$

Solución:

Resolución (c): Igualdad de la Información de Fisher

Para demostrar esta identidad, utilizaremos las siguientes condiciones de regularidad que permiten intercambiar el orden de derivación e integración:

Primera condición de regularidad: La esperanza de la primera derivada de la log-verosimilitud es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda}\right] = 0 \tag{15}$$

Segunda condición de regularidad: La esperanza de un término específico es cero:

$$\mathbb{E}_{X_1^n}\left[\frac{1}{L(X_1,\ldots,X_n|\lambda)}\frac{\partial^2 L(X_1,\ldots,X_n|\lambda)}{\partial\lambda^2}\right] = 0 \tag{16}$$

Partimos de la primera condición de regularidad:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda}\right] = 0$$

Y derivamos ambos lados de esta ecuación respecto a λ. Del lado izquierdo, bajo condiciones de regularidad podemos intercambiar la derivada con la esperanza (que es una integral):

$$\frac{\partial}{\partial\lambda}\underbrace{\mathbb{E}_{X_1^n}\left[\frac{\partial \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda}\right]}_{=0} = \mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda^2}\right]$$

Del lado derecho, derivamos la constante 0:

$$\frac{\partial}{\partial \lambda}(0) = 0$$

Por lo tanto:

$$\mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L(X_1, \ldots, X_n|\lambda)}{\partial \lambda^2}\right] = 0$$

Este resultado nos dice que la esperanza de la segunda derivada de la log-verosimilitud es cero. Ahora necesitamos conectar estos dos resultados. Partimos de la propiedad fundamental del logaritmo aplicada a la función de verosimilitud:

$$\frac{\partial \ln L(X_1, \ldots, X_n|\lambda)}{\partial \lambda} = \frac{1}{L(X_1, \ldots, X_n|\lambda)} \frac{\partial L(X_1, \ldots, X_n|\lambda)}{\partial \lambda}$$

Ahora derivamos ambos lados respecto a λ para obtener la segunda derivada. Aplicamos la regla del producto en el lado derecho, donde tenemos un producto de dos funciones: $\frac{1}{L(X_1,\ldots,X_n|\lambda)}$ y $\frac{\partial L(X_1,\ldots,X_n|\lambda)}{\partial \lambda}$. Recordemos la regla del producto: si $h(\lambda) = f(\lambda) \cdot g(\lambda)$, entonces $\frac{dh}{d\lambda} = \frac{df}{d\lambda} \cdot g + f \cdot \frac{dg}{d\lambda}$. Aplicando esto a lo siguiente:

$$\frac{\partial^2 \ln L(X_1, \ldots, X_n|\lambda)}{\partial \lambda^2} = \frac{\partial}{\partial \lambda}\left[\frac{1}{L(X_1, \ldots, X_n|\lambda)} \frac{\partial L(X_1, \ldots, X_n|\lambda)}{\partial \lambda}\right]$$

Desarrollamos usando la regla del producto:

$$= \underbrace{\frac{\partial}{\partial \lambda}\left(\frac{1}{L(X_1, \ldots, X_n|\lambda)}\right)}_{\text{derivada del primer factor}} \cdot \frac{\partial L(X_1, \ldots, X_n|\lambda)}{\partial \lambda} + \frac{1}{L(X_1, \ldots, X_n|\lambda)} \cdot \underbrace{\frac{\partial^2 L(X_1, \ldots, X_n|\lambda)}{\partial \lambda^2}}_{\text{derivada del segundo factor}}$$

Para el primer término, calculamos la derivada de $\frac{1}{L(X_1,\ldots,X_n|\lambda)}$ usando la regla de la cadena:

$$\frac{\partial}{\partial \lambda}\left(\frac{1}{L(X_1, \ldots, X_n|\lambda)}\right) = -\frac{1}{L(X_1, \ldots, X_n|\lambda)^2} \frac{\partial L(X_1, \ldots, X_n|\lambda)}{\partial \lambda}$$

Sustituyendo esto en la expresión anterior:

$$\frac{\partial^2 \ln L(X_1, \ldots, X_n|\lambda)}{\partial \lambda^2} = -\frac{1}{L(X_1, \ldots, X_n|\lambda)^2}\left(\frac{\partial L(X_1, \ldots, X_n|\lambda)}{\partial \lambda}\right)^2 + \frac{1}{L(X_1, \ldots, X_n|\lambda)} \frac{\partial^2 L(X_1, \ldots, X_n|\lambda)}{\partial \lambda^2}$$

Ahora observamos que el primer término se puede reescribir. Notemos que:

$$\frac{1}{L(X_1, \ldots, X_n|\lambda)} \frac{\partial L(X_1, \ldots, X_n|\lambda)}{\partial \lambda} = \frac{\partial \ln L(X_1, \ldots, X_n|\lambda)}{\partial \lambda}$$

Por lo tanto:

$$\frac{1}{L(X_1, \ldots, X_n|\lambda)^2}\left(\frac{\partial L(X_1, \ldots, X_n|\lambda)}{\partial \lambda}\right)^2 = \left(\frac{\partial \ln L(X_1, \ldots, X_n|\lambda)}{\partial \lambda}\right)^2$$

Finalmente, sustituyendo esto obtenemos:

$$\boxed{\frac{\partial^2 \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda^2} = -\left(\frac{\partial \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda}\right)^2 + \frac{1}{L(X_1,\ldots,X_n|\lambda)}\frac{\partial^2 L(X_1,\ldots,X_n|\lambda)}{\partial\lambda^2}}$$

Tomando esperanza en ambos lados y usando que $\mathbb{E}\left[\frac{1}{L(X_1,\ldots,X_n|\lambda)}\frac{\partial^2 L(X_1,\ldots,X_n|\lambda)}{\partial\lambda^2}\right] = 0$ (otra condición de regularidad):

$$\boxed{\mathbb{E}_{X_1^n}\left[\frac{\partial^2 \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda^2}\right] = -\mathbb{E}_{X_1^n}\left[\left(\frac{\partial \ln L(X_1,\ldots,X_n|\lambda)}{\partial\lambda}\right)^2\right]} \tag{17}$$

Esta es la **identidad de Bartlett**.

(d) [1 puntos] Demuestre que la Información de Fisher asociado al parámetro λ está dado por:

$$\mathcal{I}_n(\lambda) = \frac{n}{\lambda^2}.$$

¿Es el estimador encontrado en la parte **(a)** de mínima varianza?

Solución:

Resolución (d): Información de Fisher y Eficiencia

Calculamos la información de Fisher usando la segunda definición. De la parte (a), sabemos que:

$$\ln L(x_1,\ldots,x_n|\lambda) = -n\ln\lambda - \frac{1}{\lambda}\sum_{i=1}^n x_i \tag{18}$$

La segunda derivada es:

$$\frac{\partial^2 \ln L}{\partial\lambda^2} = \frac{n}{\lambda^2} - \frac{2}{\lambda^3}\sum_{i=1}^n x_i \tag{19}$$

Tomando la esperanza:

$$\mathbb{E}\left[\frac{\partial^2 \ln L}{\partial\lambda^2}\right] = \frac{n}{\lambda^2} - \frac{2}{\lambda^3}\mathbb{E}\left[\sum_{i=1}^n X_i\right] \tag{20}$$

$$= \frac{n}{\lambda^2} - \frac{2}{\lambda^3}\cdot n\lambda = \frac{n}{\lambda^2} - \frac{2n}{\lambda^2} = -\frac{n}{\lambda^2} \tag{21}$$

Por la identidad de Bartlett:

$$\boxed{\mathcal{I}_n(\lambda) = -\mathbb{E}\left[\frac{\partial^2 \ln L}{\partial\lambda^2}\right] = \frac{n}{\lambda^2}} \tag{22}$$

¿Es el estimador de mínima varianza?

La cota de Cramér-Rao establece que para cualquier estimador insesgado:

$$\mathrm{Var}(\hat{\lambda}) \geq \frac{1}{\mathcal{I}_n(\lambda)} = \frac{\lambda^2}{n} \tag{23}$$

De la parte (b), sabemos que $\mathrm{Var}(\hat{\lambda}_{ML}) = \lambda^2/n$. Por lo tanto:

$$\boxed{\begin{array}{l} \mathrm{Var}(\hat{\lambda}_{ML}) = \dfrac{\lambda^2}{n} = \dfrac{1}{\mathcal{I}_n(\lambda)} \\ \text{Conclusión:} \quad \hat{\lambda}_{ML} \text{ es un estimador eficiente (mínima varianza)} \end{array}}$$

(e) [1 puntos] Suponga ahora que λ es una variable aleatoria que sigue una distribución $U(a,b)$, con $a, b \in \mathbb{R}$. Demuestre que el estimador Máxima a Posteriori $\phi_{MAP}(\cdot)$ dadas las observaciones i.i.d. $X_i \sim \textit{Exponencial}\left(\frac{1}{\lambda}\right)$, $i \in \{1, ..., n\}$ está dado por:

$$\phi_{MAP}(x_1, ..., x_n) = \begin{cases} a & \text{si } a > \hat{\lambda}_{ML}(x_1, ..., x_n) \\ \hat{\lambda}_{ML}(x_1, ..., x_n) & \text{si } a \leq \hat{\lambda}_{ML}(x_1, ..., x_n) \leq b \\ b & \text{si } b < \hat{\lambda}_{ML}(x_1, ..., x_n) \end{cases}$$

donde $\hat{\lambda}_{ML}(\cdot)$ es el estimador encontrado en la parte **(a)**.
Indicación: Si $X \sim U(a,b)$ entonces su función de densidad de probabilidad es

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq x \leq b \\ 0 & \text{en otro caso} \end{cases}$$

Solución:

Resolución: Estimador MAP con Prior Uniforme

El estimador MAP maximiza la distribución a posteriori:

$$\hat{\lambda}_{MAP} = \arg\max_{\lambda} f_{\Lambda|X_1^n}(\lambda|x_1, \ldots, x_n) = \arg\max_{\lambda} f_{X_1^n|\Lambda}(x_1, \ldots, x_n|\lambda) f_\Lambda(\lambda) \tag{24}$$

Dado que $\Lambda \sim U(a,b)$:

$$f_\Lambda(\lambda) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq \lambda \leq b \\ 0 & \text{en otro caso} \end{cases} \tag{25}$$

Tomando logaritmos:

$$\hat{\lambda}_{MAP} = \arg\max_{\lambda} \left[\ln f_{X_1^n|\Lambda}(x_1, \ldots, x_n|\lambda) + \ln f_\Lambda(\lambda)\right] \tag{26}$$

Para $\lambda \in [a,b]$, el término $\ln f_\Lambda(\lambda) = -\ln(b-a)$ es constante, por lo que:

$$\hat{\lambda}_{MAP} = \arg\max_{\lambda \in [a,b]} \ln L(x_1, \ldots, x_n|\lambda) \tag{27}$$

De la parte (a), sabemos que si maximizamos $\ln L(x_1, \ldots, x_n|\lambda)$ sobre **todo** $\mathbb{R}^+$ (es decir, sin ninguna restricción sobre λ), el máximo se alcanza en $\hat{\lambda}_{ML} = \bar{x}$. A este valor lo llamamos el **máximo no restringido** o **máximo global sin restricciones**.

Sin embargo, en este problema debemos maximizar $\ln L$ **restringido** al intervalo $[a, b]$, porque la distribución a priori $U(a, b)$ nos dice que λ solo puede tomar valores en $[a, b]$ (fuera de este intervalo, $f_\Lambda(\lambda) = 0$, por lo que la posteriori también es cero). Entonces, el problema se reduce a: ¿dónde está el máximo de $\ln L$ cuando estamos restringidos a buscar solo en $[a, b]$?

De la parte (a) también sabemos que $\ln L$ es una función **cóncava** (con un único máximo global). Esto nos permite analizar tres escenarios posibles:

1. **Si $\hat{\lambda}_{ML} \in [a, b]$:** El máximo no restringido (el pico de la función) está **dentro** del intervalo $[a, b]$ donde estamos buscando. Como la función tiene un único máximo y está dentro del dominio permitido, entonces:
$$\hat{\lambda}_{MAP} = \hat{\lambda}_{ML} \tag{28}$$
Conclusión: El máximo restringido coincide con el máximo no restringido.

2. **Si $\hat{\lambda}_{ML} < a$:** El máximo no restringido está a la **izquierda** del intervalo $[a, b]$.

   Como $\ln L$ es cóncava con máximo en $\hat{\lambda}_{ML}$, sabemos que:

   - Para $\lambda < \hat{\lambda}_{ML}$: la función es **creciente** (sube hacia el máximo)
   - Para $\lambda > \hat{\lambda}_{ML}$: la función es **decreciente** (baja desde el máximo)

   Dado que todo el intervalo $[a, b]$ está a la derecha de $\hat{\lambda}_{ML}$ (pues $a > \hat{\lambda}_{ML}$), la función es decreciente en todo $[a, b]$. Por lo tanto, el valor más alto dentro de $[a, b]$ se alcanza en el punto más cercano al máximo global, que es $\lambda = a$:
$$\hat{\lambda}_{MAP} = a \tag{29}$$
Conclusión: El máximo restringido está en la frontera izquierda.

3. **Si $\hat{\lambda}_{ML} > b$:** El máximo no restringido está a la **derecha** del intervalo $[a, b]$.

   Como todo el intervalo $[a, b]$ está a la izquierda de $\hat{\lambda}_{ML}$ (pues $b < \hat{\lambda}_{ML}$), la función es **creciente** en todo $[a, b]$ (aún está subiendo hacia el máximo). Por lo tanto, el valor más alto dentro de $[a, b]$ se alcanza en el punto más cercano al máximo global, que es $\lambda = b$:
$$\hat{\lambda}_{MAP} = b \tag{30}$$
Conclusión: El máximo restringido está en la frontera derecha.

Por lo tanto:

$$\boxed{\phi_{MAP}(x_1, \ldots, x_n) = \begin{cases} a & \text{si } a > \hat{\lambda}_{ML}(x_1, \ldots, x_n) \\ \hat{\lambda}_{ML}(x_1, \ldots, x_n) & \text{si } a \leq \hat{\lambda}_{ML}(x_1, \ldots, x_n) \leq b \\ b & \text{si } b < \hat{\lambda}_{ML}(x_1, \ldots, x_n) \end{cases}} \tag{31}$$

Esta es una **proyección** del estimador ML al dominio $[a, b]$, lo que tiene sentido ya que la distribución uniforme tiene soporte compacto.